HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I

BÁO CÁO TUẦN

HỌC PHẦN: THỰC TẬP CƠ SỞ

ĐỀ TÀI XÂY DỰNG HỆ THỐNG ĐIỂM DANH SINH VIÊN THỜI GIAN THỰC DỰA TRÊN NHẬN DIỆN KHUÔN MẶT VÀ QUẢN LÝ PHIÊN HỌC

Giảng viên hướng dẫn : **TS. Kim Ngọc Bách**
Mã sinh viên : **B23DCCN579**
Tên sinh viên : **Lê Minh Nam**
Lớp hành chính : **D23CQCN05-B**
Nhóm thực tập : **11**

Hà Nội – 2026

MỤC LỤC

Phụ lục hình ảnh **3**

Convolutional Neural Networks và Face Recognition **4**

I. Mục tiêu **4**

II. Nội dung nghiên cứu **4**

2.1. Artificial Neural Networks (Mạng nơ-ron nhân tạo) 4

2.1.1. Tổng quan về Neural Network 4

2.1.2. Hàm tuyến tính và hàm phi tuyến 4

2.1.3. Neuron trong mạng nơ-ron 5

2.1.4. Layer trong Neural Network 5

2.1.5. Neural Network nhiều lớp 6

2.2. Convolutional Neural Networks (CNN) 7

2.2.1. Tổng quan về CNN 7

2.2.2. Cấu trúc của mạng CNN 7

2.2.3. Ưu điểm của CNN trong xử lý ảnh 11

2.3. Face Recognition 11

Tài liệu tham khảo **14**

Phụ lục hình ảnh

Hình 1. Cấu trúc của một mạng Neural Network nhiều lớp.....6
Hình 2. Kiến trúc tổng quát của mạng Convolutional Neural Network (CNN).....7

Convolutional Neural Networks và Face Recognition

I. Mục tiêu

Tìm hiểu các kiến thức nền tảng liên quan đến Convolutional Neural Networks (CNN) và Face Recognition, nhằm xây dựng cơ sở lý thuyết cho việc thiết kế hệ thống điểm danh sinh viên bằng nhận diện khuôn mặt. Việc nghiên cứu các mô hình và thuật toán trong lĩnh vực thị giác máy tính giúp hiểu rõ nguyên lý hoạt động của hệ thống nhận diện khuôn mặt trước khi tiến hành triển khai thực tế.

II. Nội dung nghiên cứu

2.1. Artificial Neural Networks (Mạng nơ-ron nhân tạo)

2.1.1. Tổng quan về Neural Network

Artificial Neural Network (ANN), hay còn gọi là Neural Network là mô hình học máy được xây dựng dựa trên nguyên lý hoạt động của hệ thần kinh sinh học. Mạng nơ-ron bao gồm nhiều đơn vị xử lý nhỏ gọi là neuron (nơ-ron), được kết nối với nhau để học các mối quan hệ giữa dữ liệu đầu vào và đầu ra.

Trong các bài toán học máy, mục tiêu của mô hình là tìm ra mối quan hệ giữa dữ liệu đầu vào và kết quả đầu ra. Neural Network có khả năng học các mối quan hệ này thông qua quá trình huấn luyện bằng dữ liệu.

Nhờ cấu trúc nhiều lớp và khả năng học phi tuyến, Neural Network được ứng dụng rộng rãi trong nhiều lĩnh vực như nhận dạng hình ảnh, xử lý ngôn ngữ tự nhiên và nhận diện khuôn mặt.

2.1.2. Hàm tuyến tính và hàm phi tuyến

Trong mô hình học máy, mối quan hệ giữa input và output có thể được mô tả bằng các hàm toán học. Hai loại hàm thường được sử dụng là hàm tuyến tính và hàm phi tuyến.

*** Hàm tuyến tính (Linear Function)**

Hàm tuyến tính mô tả mối quan hệ đơn giản giữa đầu vào và đầu ra. Dạng tổng quát của hàm tuyến tính:

$$y = wx + b$$

Trong đó:

- x là giá trị đầu vào.
- w là trọng số (weight).

- b là hệ số bias.

- y là đầu ra của mô hình.

Hàm tuyến tính dễ tính toán nhưng không thể biểu diễn các mối quan hệ phức tạp trong dữ liệu.

*** Hàm phi tuyến (Non-linear Function)**

Để mô hình có khả năng học các mối quan hệ phức tạp hơn, người ta sử dụng hàm kích hoạt phi tuyến. Một số hàm kích hoạt phổ biến bao gồm:

- ReLU (Rectified Linear Unit)

- Sigmoid

- Tanh

Các hàm này giúp mô hình học được các đặc trưng phức tạp trong dữ liệu, đặc biệt trong các bài toán xử lý và nhận dạng hình ảnh.

2.1.3. Neuron trong mạng nơ-ron

Một neuron là đơn vị cơ bản của mạng nơ-ron. Mỗi neuron thực hiện hai bước chính:

- Tính toán tổng có trọng số của các giá trị đầu vào.

- Áp dụng hàm kích hoạt để tạo ra đầu ra.

Công thức tính toán của một neuron:

$$z = w_1x_1 + w_2x_2 + \cdots + w_nx_n + b$$

Sau đó giá trị z được đưa qua hàm kích hoạt: y = f(z)

Trong đó:

- $x_1, x_2, \dots, x_n$ là các giá trị đầu vào.

- $w_1, w_2, \dots, w_n$ là các trọng số.

- b là bias.

- f(z) là hàm kích hoạt.

Nhờ sự kết hợp giữa hàm tuyến tính và hàm phi tuyến, neuron có thể học được cả mối quan hệ đơn giản và phức tạp giữa input và output.

2.1.4. Layer trong Neural Network

Layer (lớp) là tập hợp của nhiều neuron. Các neuron trong cùng một layer nhận cùng dữ liệu đầu vào, sử dụng cùng một hàm kích hoạt nhưng có trọng số khác nhau. Do đó mỗi neuron sẽ tạo ra một đầu ra khác nhau.

Trong cùng một layer, các neuron không kết nối trực tiếp với nhau, mà chỉ nhận dữ liệu từ layer trước đó.

Một mạng neural thường bao gồm ba loại layer:

- Input layer: lớp nhận dữ liệu đầu vào.
- Hidden layer: lớp trung gian xử lý dữ liệu.
- Output layer: lớp đưa ra kết quả cuối cùng.

2.1.5. Neural Network nhiều lớp

Neural Network được xây dựng bằng cách kết nối nhiều layer với nhau theo một cấu trúc nhất định. Quá trình học của mạng diễn ra bằng cách điều chỉnh các trọng số thông qua thuật toán Backpropagation kết hợp với phương pháp Gradient Descent.

Trong quá trình huấn luyện, mô hình sẽ giảm sai số giữa kết quả dự đoán và dữ liệu thực tế bằng cách cập nhật trọng số qua nhiều lần lặp (iterations).

Tuy nhiên, khi xử lý dữ liệu hình ảnh có kích thước lớn, mạng neural truyền thống gặp hạn chế do số lượng tham số rất lớn. Vì vậy, một kiến trúc cải tiến gọi là Convolutional Neural Network (CNN) đã được phát triển để xử lý ảnh hiệu quả hơn.

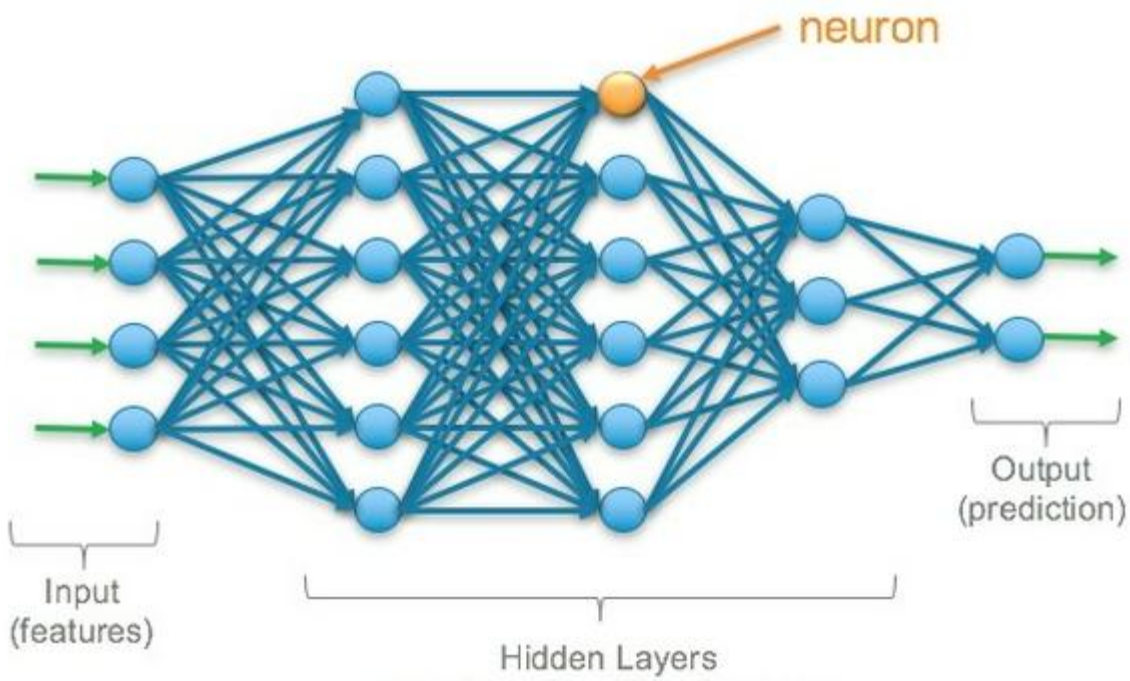

Hình 1. Cấu trúc của một mạng Neural Network nhiều lớp

2.2. Convolutional Neural Networks (CNN)

2.2.1. Tổng quan về CNN

Convolutional Neural Networks (CNN) là một kiến trúc mạng nơ-ron sâu được thiết kế đặc biệt để xử lý dữ liệu dạng lưới như hình ảnh hoặc video. Khác với mạng nơ-ron truyền thống (Fully Connected Neural Network), CNN tận dụng cấu trúc không gian của ảnh thông qua các phép tích chập (convolution operation) để trích xuất đặc trưng hiệu quả hơn.

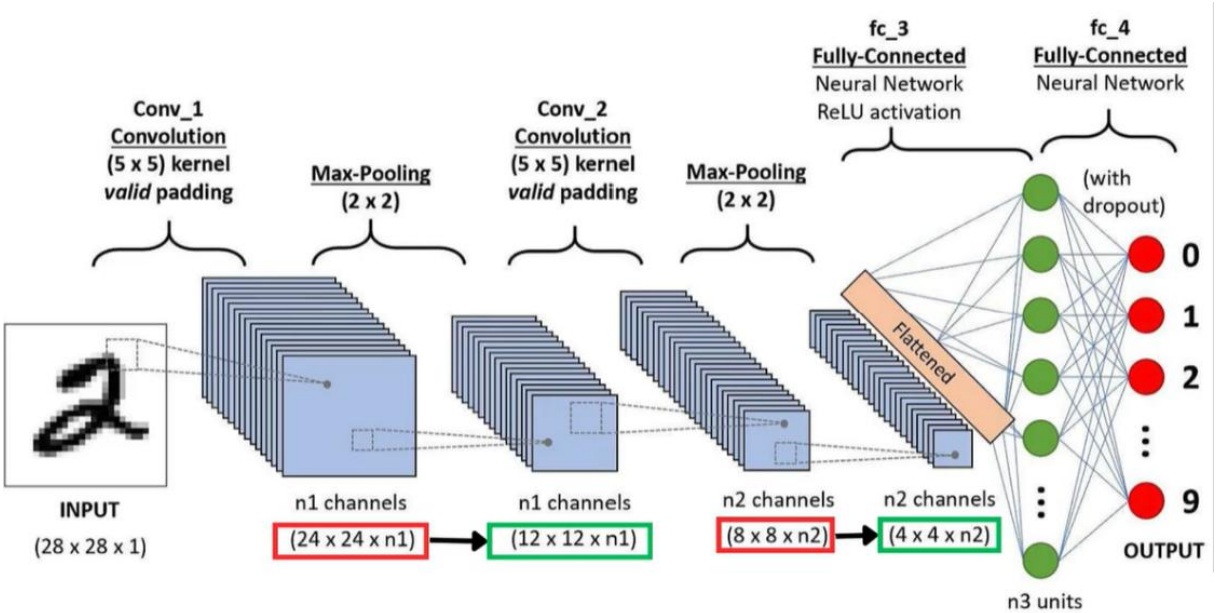

Hình 2. Kiến trúc tổng quát của mạng Convolutional Neural Network (CNN)

CNN đã trở thành nền tảng của hầu hết các hệ thống thị giác máy tính hiện đại, bao gồm nhận diện khuôn mặt, phát hiện đối tượng, phân loại ảnh và phân đoạn ảnh. Theo LeCun et al. (2015), CNN có khả năng tự động học các đặc trưng quan trọng của dữ liệu mà không cần thiết kế đặc trưng thủ công như các phương pháp truyền thống.

2.2.2. Cấu trúc của mạng CNN

Một mạng CNN điển hình gồm nhiều lớp khác nhau, mỗi lớp thực hiện một chức năng riêng trong quá trình trích xuất và xử lý đặc trưng.

a) Convolution Layer

Lớp tích chập (Convolution Layer) thực hiện phép tích chập giữa bộ lọc (kernel) và ảnh đầu vào nhằm trích xuất các đặc trưng cục bộ của hình ảnh. Kernel thường có kích thước nhỏ (ví dụ: 3×3 hoặc 5×5) và được học trong quá trình huấn luyện. Bộ lọc này di chuyển qua dữ liệu đầu vào và thực hiện phép nhân tích chập trên các vùng con, từ đó phát hiện ra các đặc trưng cục bộ.

Công thức tích chập có thể được biểu diễn như sau:

$$S(i,j) = (X * K)(i,j) = \sum_m \sum_n X(i+m, j+n)K(m,n)$$

Trong đó:

- X là ảnh đầu vào.

- K là kernel.

- S(i, j) là giá trị đặc trưng tại vị trí (i, j).

* Ưu điểm:

- Khả năng phát hiện ra các đặc trưng cục bộ như cạnh, góc, kết cấu và các chi tiết cục bộ, hay các cấu trúc phức tạp hơn trong ảnh.

- Tiết kiệm tham số, vì các bộ lọc chỉ 1 tập nhỏ các trọng số và áp dụng trên toàn bộ đầu vào, làm giảm nguy cơ quá khớp, giảm tài nguyên tính toán.

- Tính bất biến đối với vị trí.

- Giữ nguyên cấu trúc không gian.

* Nhược điểm:

- Không phù hợp cho các dữ liệu không có cấu trúc không gian (Ví dụ dạng bảng).

- Khả năng học hạn chế đối với các đặc trưng toàn cục.

Lớp convolution thường được sử dụng trong các mô hình tuần tự hoặc xử lý thời gian, có thể sử dụng để phát hiện các mẫu cục bộ trong dữ liệu tuần tự hoặc chuỗi thời gian, như chuỗi văn bản hoặc tín hiệu âm thành.

b) Activation Function

Sau lớp tích chập, các giá trị đầu ra thường được đưa qua hàm kích hoạt (activation function) để tạo tính phi tuyến cho mô hình.

Hàm phổ biến nhất là Rectified Linear Unit (ReLU):

$$f(x) = \max(0, x)$$

ReLU giúp tăng tốc độ huấn luyện và giảm vấn đề vanishing gradient.

* Hiện tượng vanishing gradient:

Hiện tượng vanishing Gradient là hiện tượng trong quá trình huấn luyện mạng nơ-ron sâu, khi các giá trị gradient trở nên rất nhỏ trong quá trình lan truyền ngược (backpropagation). Khi gradient quá nhỏ, các trọng số ở các lớp đầu của mạng được cập nhật rất chậm hoặc gần như không thay đổi, làm cho quá trình học của mô hình bị chậm lại hoặc dừng lại.

Hiện tượng này thường xảy ra trong các mạng nơ-ron có nhiều lớp (deep neural networks), đặc biệt khi sử dụng các hàm kích hoạt như sigmoid hoặc tanh.

c) Pooling Layer

Pooling Layer được sử dụng để giảm kích thước của feature map nhằm giảm số lượng tham số và tăng tính bất biến đối với dịch chuyển nhỏ trong ảnh. Lớp hoạt động bằng cách chia dữ liệu đầu vào thành các vùng con, sau đó áp dụng 1 phép tính (thường là max - lấy phần tử tối đa hoặc average - lấy phần tử trung bình) để rút gọn thông tin của các vùng đó thành 1 giá trị đại diện.

Phương pháp phổ biến nhất là Max Pooling, trong đó giá trị lớn nhất trong một vùng (ví dụ 2×2) được giữ lại:

$$y = \max(x_1, x_2, \dots, x_n)$$

* Ưu điểm:

- Làm giảm kích thước và số lượng tham số của mô hình.

- Ngăn chặn hiện tượng quá khớp (overfitting).

- Giúp tăng tính khái quát hóa của mô hình, giúp mô hình không phụ thuộc vào vị trí chính xác của các đặc trưng, từ đó làm tăng khả năng khái quá hóa và độ chính xác trên dữ liệu kiểm thử.

* Nhược điểm:

- Khả năng có thể làm mất mát thông tin chi tiết, quan trọng khi giảm kích thước dữ liệu đầu vào.

- Không linh hoạt với các đặc trưng toàn cục.

- Làm giảm độ phân giải.

d) Fully Connected Layer

Ở các lớp cuối của CNN, các đặc trưng đã trích xuất sẽ được kết nối đầy đủ (fully connected) để đưa ra kết quả dự đoán hoặc embedding đặc trưng.

* Ưu điểm:

- Khả năng kết nối mạnh mẽ, cho phép nó học được các mối quan hệ phức tạp.

- Phù hợp với các bài toán phân loại: Fully Connected Layer ở cuối của mạng neural có thể tổng hợp các đặc trưng của layer trước đó để đưa ra dự đoán cuối cùng cho bài toán phân loại.

* Nhược điểm:

- Tốn tài nguyên tính toán vào bộ nhớ.

- Khả năng dẫn đến hiện tượng quá khớp (overfitting). Do có nhiều trọng số, đặc biệt khi kích thước dữ liệu không đủ lớn so với kích thước của layer.

- Không phù hợp với dữ liệu có cấu trúc: Không lưu trữ các thông tin về cấu trúc không gian và thời gian của dữ liệu.

Trong bài toán nhận diện khuôn mặt hiện đại, fully connected layer thường được sử dụng để sinh vector đặc trưng (embedding) thay vì dự đoán nhãn trực tiếp.

e) Dropout Layer

Dropout là một kỹ thuật regularization được sử dụng để giảm hiện tượng overfitting trong mạng nơ-ron. Trong quá trình huấn luyện, Dropout Layer sẽ vô hiệu hóa ngẫu nhiên một số nơ-ron bằng cách thiết lập giá trị của chúng bằng 0 với một tỷ lệ xác suất nhất định. Kỹ thuật này nhằm mục đích ngăn mô hình quá phụ thuộc vào một tập hợp nhỏ các nơ-ron nhất định và khuyến khích các nơ-ron học được các đặc trưng đa dạng hơn.

Trong Dropout Layer có một tỷ lệ xác suất được gọi là Dropout Rate, sẽ được thiết lập, thường nằm trong khoảng từ 0.2 đến 0.5.

Dropout Layer có ba chức năng chính:

- Ngăn chặn hiện tượng Overfitting: Giúp giảm khả năng mạng học quá sát với dữ liệu huấn liệu, từ đó làm tăng khả năng tổng quát hóa trên dữ liệu mới.

- Tăng cường tính mạnh mẽ của mô hình: Bằng cách tắt ngẫu nhiên các nơ-ron trong mô hình huấn luyện thì Dropout Layer giúp mạng nơ-ron học cách thích nghi với dữ liệu mà không phụ thuộc quá nhiều vào bất kỳ nơ-ron cụ thể nào.

- Giả lập các tập hợp khác nhau: Dropout Layer có thể coi là 1 cách để giả lập nhiều mô hình khác nhau do việc vô hiệu hóa các nơ-ron ngẫu nhiên.

* Ưu điểm:

- Giảm hiện tượng quá khớp của mô hình.

- Đơn giản và hiệu quả: Dropout là một kỹ thuật đơn giản nhưng có thể cải thiện đáng kể hiệu suất của mô hình về tính hiệu quả, đặc biệt trong các mạng nơ-ron có nhiều layer.

* Nhược điểm:

- Nếu sử dụng không phù hợp có thể làm giảm hiệu quả trong quá trình huấn luyện. Nếu thiết lập Dropout Rate không phù hợp thì Dropout có thể làm giảm số lượng

nơ-ron hoạt động trong quá trình huấn luyện, từ đó làm giảm tốc độ hội tụ hoặc yêu cầu thời gian huấn luyện lâu hơn.

- Không phù hợp cho một số loại mô hình như mạng nơ-ron hồi quy, trong đó các kết nối tuần tự trong chuỗi thời gian cần duy trì tính nhất quán.

f) Normalization Layer (Batch Normalization)

Batch Normalization là kỹ thuật chuẩn hóa dữ liệu đầu vào của mỗi layer trong mạng nơ-ron. Phương pháp này giúp ổn định phân phối của dữ liệu trong quá trình huấn luyện, từ đó giúp mô hình hội tụ nhanh hơn và cải thiện hiệu suất của mạng sâu.

* Ưu điểm: Giúp tránh hiện tượng Overfitting của mạng nơ-ron tích chập cũng như làm tăng độ chính xác của mô hình.

* Nhược điểm: Trong nhiều trường hợp thường không hiệu quả trong mạng neural tuần tự vì sự thay đổi của batch trong chuỗi thời gian có thể không phản ánh đúng sự biến đổi của các giá trị. Yêu cầu Batch đủ lớn để tính toán giá trị trung bình và phương sai một cách chính xác.

2.2.3. Ưu điểm của CNN trong xử lý ảnh

CNN có nhiều ưu điểm so với các phương pháp truyền thống:

- Khả năng tự động học đặc trưng từ dữ liệu.
- Giảm số lượng tham số nhờ cơ chế weight sharing.
- Khả năng tổng quát tốt đối với các biến đổi nhỏ của ảnh.
- Hiệu quả cao trong các bài toán thị giác máy tính.

Nhờ những ưu điểm này, CNN đã trở thành nền tảng của hầu hết các hệ thống nhận diện khuôn mặt hiện đại.

2.3. Face Recognition

2.3.1. Tổng quan về nhận diện khuôn mặt

Face Recognition là quá trình xác định hoặc xác minh danh tính của một người dựa trên đặc trưng khuôn mặt. Một hệ thống nhận diện khuôn mặt hiện đại thường gồm ba bước chính:

- Face Detection: phát hiện vị trí khuôn mặt trong ảnh.
- Feature Extraction: trích xuất đặc trưng khuôn mặt bằng mô hình học sâu.
- Face Matching: so khớp đặc trưng với cơ sở dữ liệu để xác định danh tính.

Các hệ thống hiện đại không thực hiện phân loại trực tiếp mà sử dụng phương pháp embedding-based recognition, trong đó mỗi khuôn mặt được biểu diễn bằng một vector đặc trưng trong không gian nhiều chiều.

2.3.2. Face Embedding

Face embedding là vector đặc trưng đại diện cho khuôn mặt trong không gian đặc trưng. Các ảnh của cùng một người sẽ có embedding gần nhau, trong khi ảnh của người khác sẽ nằm xa nhau.

Việc so sánh hai khuôn mặt thường được thực hiện bằng cosine similarity:

$$sim(A, B) = \frac{A.B}{\|A\|\|B\|}$$

Nếu giá trị similarity lớn hơn một ngưỡng xác định trước, hai khuôn mặt được xem là cùng một người.

2.3.3. Mô hình FaceNet

FaceNet được đề xuất bởi Schroff et al. (2015). Mô hình này sử dụng phương pháp Deep Metric Learning để học embedding khuôn mặt.

FaceNet sử dụng hàm mất mát Triplet Loss, bao gồm ba thành phần:

- Anchor (ảnh của một người).
- Positive (ảnh khác của cùng người).
- Negative (ảnh của người khác).

Mục tiêu của hàm mất mát là đảm bảo khoảng cách giữa Anchor và Positive nhỏ hơn khoảng cách giữa Anchor và Negative.

$$L = \max(d(a, p) - d(a, n) + \alpha, 0)$$

Trong đó:

- d(a, p) là khoảng cách giữa anchor và positive.
- d(a, n) là khoảng cách giữa anchor và negative.
- α là margin.

Phương pháp này giúp mô hình học được không gian đặc trưng hiệu quả cho nhận diện khuôn mặt.

2.3.4. Mô hình ArcFace

ArcFace là một cải tiến của FaceNet được đề xuất bởi Deng et al. (2019). ArcFace sử dụng Additive Angular Margin Loss nhằm tăng khoảng cách giữa các lớp trong không gian đặc trưng.

ArcFace chuẩn hóa embedding và trọng số lớp trước khi tính toán softmax, từ đó cải thiện khả năng phân biệt giữa các danh tính khác nhau.

Nhờ cơ chế này, ArcFace đạt hiệu suất cao trên nhiều bộ dữ liệu chuẩn như:

- LFW (Labeled Faces in the Wild).
- MegaFace.
- MS-Celeb-1M.

ArcFace hiện được xem là một trong những phương pháp nhận diện khuôn mặt chính xác nhất trong các hệ thống hiện đại.

2.3.5. Ứng dụng của Face Recognition

Công nghệ nhận diện khuôn mặt được ứng dụng rộng rãi trong nhiều lĩnh vực:

- Hệ thống chấm công nhân viên.
- Kiểm soát ra vào tòa nhà.
- Xác thực danh tính trong thiết bị di động.
- Hệ thống điểm danh tự động trong lớp học.

Trong dự án này, công nghệ nhận diện khuôn mặt được áp dụng để xây dựng hệ thống điểm danh sinh viên theo phiên học, giúp tự động xác định danh tính và ghi nhận thời gian có mặt trong lớp.

Tài liệu tham khảo

[1] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.

[2] F. Schroff, D. Kalenichenko, and J. Philbin, “FaceNet: A unified embedding for face recognition and clustering,” in Proc. *IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2015, pp. 815–823.

[3] J. Deng, J. Guo, N. Xue, and S. Zafeiriou, “ArcFace: Additive angular margin loss for deep face recognition,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2019, pp. 4690–4699.

[4] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.

[5] Wikipedia, “Mạng thần kinh tích chập,” *Wikipedia*, 2024. [Online]. Available: https://vi.wikipedia.org/wiki/M%E1%BA%A1ng_th%E1%BA%A7n_kinh_t%C3%ADch_ch%E1%BA%ADp

[6] FPT AI, “Convolutional Neural Network là gì?”, *FPT.AI*, 2023. [Online]. Available: https://fpt.ai/vi/bai-viet/convolutional-neural-network/